

# Introdução à Estatística Multivariada

Disciplina: Modelagem Estatística

Instrutor: Luiz Max Carvalho

Monitores: Eduardo Adame & Ezequiel Braga

Março 2024

## Introdução

A ideia desse documento é auxiliar na transição para a Estatística Multivariada. É importante estar bem afiado em Álgebra Linear e (obviamente) nos conteúdos vistos em Inferência Estatística. As referências principais serão o [Petersen e Pedersen \(2008\)](#) e o [Soch et al. \(2024\)](#).

## Vetores Aleatórios

Ao invés de lidarmos com uma variável aleatória  $X \in \mathcal{X} \subseteq \mathbb{R}$ , com  $\mu = \mathbb{E}[X]$  e  $\sigma^2 = \mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2]$ , introduzimos agora vetores aleatórios. Por exemplo,  $\mathbf{X} \in \mathcal{X}^n$ , com **vetor de média**  $\boldsymbol{\mu}$  tal que  $\mu_i = \mathbb{E}[X_i]$  (denotamos  $\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}]$ ) e **matriz de covariância**  $\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top]$ , que vem de um produto externo. Lembre-se que perdemos comutatividade ao trabalhar em  $\mathcal{X}^{n \times n}$ .

## Formas Quadráticas

Uma forma quadrática é uma expressão polinomial em que cada termo possui grau 2. Por exemplo,  $y_1^2 + y_2^2$  e  $2y_1^2 + y_2^2 + 3y_1y_2$  são formas quadráticas em  $y_1$  e  $y_2$ , mas  $y_1^2 + y_2^2 + 2y_1$  e  $y_1^2 + 3y_2^2 + 2$  não são.

Seja  $\mathbf{A}$  uma matriz simétrica. Então, a expressão  $\mathbf{y}^\top \mathbf{A} \mathbf{y} = \sum_i \sum_j a_{ij} y_i y_j$  é uma forma quadrática nos  $y_i$ 's. Analogamente, a expressão  $(\mathbf{y} - \boldsymbol{\mu})^\top \mathbf{V}^{-1} (\mathbf{y} - \boldsymbol{\mu})$  é uma forma quadrática nos termos  $(y_i - \mu_i)$ . Quando  $\mathbf{y}^\top \mathbf{A} \mathbf{y} > 0$ ,  $\forall \mathbf{y} \neq \mathbf{0}$ , diz-se que a forma quadrática (e a matriz  $\mathbf{A}$ ) é positiva definida. Além disso, o posto da matrix  $\mathbf{A}$  é chamado de número de graus de liberdade da forma quadrática.

**Teorema (Cochran).** *Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória da distribuição normal com média 0 e varância  $\sigma^2$ . Sejam  $Q = \sum_{i=1}^n X_i^2$  e  $Q_1, \dots, Q_k$  formas quadráticas tais que  $Q = \sum_{i=1}^k Q_i$ , onde  $Q_i$  possui  $m_i$  graus de liberdade. Então,  $Q_1, \dots, Q_k$  são variáveis aleatórias independentes com  $\frac{Q_i}{\sigma^2} \sim \chi^2(m_i)$  ( $i = 1, \dots, k$ ) se, e somente se,  $\sum_{i=1}^k m_i = n$ .*

Uma consequência do teorema acima é que se  $X_1^2 \sim \chi^2(m)$  e  $X_2^2 \sim \chi^2(k)$  são independentes, então,  $X^2 = X_1^2 - X_2^2 \sim \chi^2(m - k)$ , desde que  $X^2 \geq 0$  e  $m > k$ .

## Identidades Relevantes

Seja  $\mathbf{X}$  variável aleatória com média  $\boldsymbol{\mu}$  e matriz de covariância  $\boldsymbol{\Sigma}$

- $\mathbb{E}[\mathbf{A}\mathbf{X} + \mathbf{B}] = \mathbf{A}\boldsymbol{\mu} + \mathbf{B}$
- $\mathbb{V}[\mathbf{A}\mathbf{X}] = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$
- $\mathbb{E}[\mathbf{X}\mathbf{X}^\top] = \boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^\top$

## Matrizes de Covariância

A noção de variância passa a ser representada, em geral, em termos de covariância. Sabemos desde a parte univariada que  $\text{Cov}[X, X] = \mathbb{V}[X]$  e isso continua valendo aqui.

Sabemos também que essa matriz será, ao menos, semi-definida positiva, pois  $\forall w \in \mathbb{R}^n$  temos que:

$$\begin{aligned}\mathbb{V}[w^\top \mathbf{X}] &= w^\top \mathbb{V}[\mathbf{X}]w = w^\top \mathbb{E} \left[ (\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top \right] w, \\ &= \mathbb{E} \left[ w^\top (\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top w \right], \\ &= \mathbb{E} \left[ \left[ w^\top (\mathbf{X} - \mathbb{E}[\mathbf{X}]) \right]^2 \right] \geq 0.\end{aligned}$$

## Principais Distribuições Multivariadas

### Multivariada Normal

Seja  $\mathbf{X} \in \mathbb{R}^n$ . Então,  $\mathbf{X}$  é normalmente distribuído com média  $\boldsymbol{\mu} \in \mathbb{R}^n$  e matriz de covariância  $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$  ( $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ) se, e somente se, sua p.d.f é dada por

$$f(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^n |\boldsymbol{\Sigma}|}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right].$$

### Dirichlet (Generalização da Beta)

Seja  $\mathbf{X} \in \mathbb{R}^n$ . Então,  $\mathbf{X}$  segue a distribuição Dirichlet com parâmetros de concentração  $\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_n]$  ( $\mathbf{X} \sim \text{Dir}(\boldsymbol{\alpha})$ ) se, e somente se, sua p.d.f é dada por

$$f(\mathbf{x}; \boldsymbol{\alpha}) = \frac{\Gamma(\sum_{i=1}^n \alpha_i)}{\prod_{i=1}^n \Gamma(\alpha_i)} \prod_{i=1}^n x_i^{\alpha_i - 1},$$

onde  $\alpha_i > 0$ ,  $\forall i = 1, \dots, n$  e a densidade é zero se  $x_i \notin [0, 1]$  para algum  $i = 1, \dots, n$  ou  $\sum_{i=1}^n x_i \neq 1$ .

## Multinomial (Generalização da Binomial)

Seja  $\mathbf{X} \in \mathbb{R}^k$ . Então,  $\mathbf{X}$  segue a distribuição multinomial com número de tentativas  $n$  e probabilidades  $p_1, \dots, p_k$  ( $\mathbf{X} \sim \text{Mult}(n, [p_1, \dots, p_k])$ ) se  $\mathbf{X}$  é o número de observações pertencentes a  $k$  categorias distintas em  $n$  ensaios independentes, cuja densidade é dada por

$$f(\mathbf{x}; n, p_1, \dots, p_k) = \frac{n!}{\prod_{i=1}^k x_i!} \prod_{i=1}^k p_i^{x_i},$$

onde  $\sum_{i=1}^k x_i = n$ ;  $x_i \geq 0, \forall i = 1, \dots, k$ ; e  $\sum_{i=1}^k p_i = 1$ .

## Pareto

Seja  $\mathbf{X} \in \mathbb{R}^k$ . Então,  $\mathbf{X}$  segue a distribuição de Pareto com parâmetros  $a = (a_1, \dots, a_k)$  e  $p$  se sua p.d.f é dada por

$$f(\mathbf{x}; a, p) = \frac{p(p+1) \dots (p+k-1)}{\left(\prod_{i=1}^k a_i\right) \left[\left(\sum_{i=1}^k a_i^{-1} x_i\right) - k + 1\right]^{p+k}},$$

para  $x_i > a_i > 0, i = 1, \dots, k, p > 0$ .

## Normal Matricial

Seja  $\mathbf{X} \in \mathbb{R}^{n \times p}$ . Então,  $\mathbf{X}$  segue a distribuição normal com média  $M$ , covariância entre linhas  $U$  e covariância entre colunas  $V$  ( $\mathbf{X} \sim \mathcal{MN}(M, U, V)$ ) se, e somente se, sua p.d.f é dada por

$$f(\mathbf{X}; M, U, V) = \frac{1}{\sqrt{(2\pi)^{np} |V| |U|}} \exp \left[ -\frac{1}{2} \text{tr}(V^{-1}(\mathbf{X} - M)^\top U^{-1}(\mathbf{X} - M)) \right].$$

## Wishart (Generalização da Gamma)

Seja  $\mathbf{X} \in \mathbb{R}^{n \times p}$ , com  $\mathbf{X} \sim \mathcal{MN}(0, I_n, V)$ . Tome  $S = \mathbf{X}^\top \mathbf{X}$ . Então,  $S$  segue a distribuição de Wishart com matriz de escala  $V$  e  $n$  graus de liberdade ( $S \sim \mathcal{W}(V, n)$ ), com  $n > p - 1$  e  $V$  simétrica positiva definida. Sua p.d.f é dada por

$$f(\mathbf{X}; V, n) = \frac{1}{2^{np/2} |V|^{n/2} \Gamma_p(\frac{n}{2})} |\mathbf{X}|^{(n-p-1)/2} \exp \left( -\frac{1}{2} \text{tr}(V^{-1} \mathbf{X}) \right),$$

onde  $\Gamma_p(\frac{n}{2}) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma(\frac{n}{2} - \frac{j-1}{2})$ .

## Recursos para manipulação algébrica

### Completar Quadrado Multidimensional

Tome  $\mathbf{X}$  matriz simétrica positiva definida  $d \times d$  e  $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$ . Vale que

$$\mathbf{u}^\top \mathbf{X} \mathbf{u} - 2\mathbf{v}^\top \mathbf{u} = \left( \mathbf{u} - \mathbf{X}^{-1} \mathbf{v} \right)^\top \mathbf{X} \left( \mathbf{u} - \mathbf{X}^{-1} \mathbf{v} \right) - \mathbf{v}^\top \mathbf{X}^{-1} \mathbf{v}.$$

Para verificar isso, basta expandir a forma quadrática e usar a simetria da matriz  $\mathbf{X}$ :

$$\begin{aligned} \left( \mathbf{u} - \mathbf{X}^{-1} \mathbf{v} \right)^\top \mathbf{X} \left( \mathbf{u} - \mathbf{X}^{-1} \mathbf{v} \right) &= \left( \mathbf{u}^\top \mathbf{X} - \mathbf{v}^\top \left( \mathbf{X}^\top \right)^{-1} \mathbf{X} \right) \left( \mathbf{u} - \mathbf{X}^{-1} \mathbf{v} \right), \\ &= \left( \mathbf{u}^\top \mathbf{X} - \mathbf{v}^\top \right) \left( \mathbf{u} - \mathbf{X}^{-1} \mathbf{v} \right), \\ &= \mathbf{u}^\top \mathbf{X} \mathbf{u} - \mathbf{u}^\top \mathbf{v} - \mathbf{v}^\top \mathbf{u} + \mathbf{v}^\top \mathbf{X}^{-1} \mathbf{v}, \\ &= \mathbf{u}^\top \mathbf{X} \mathbf{u} - 2\mathbf{u}^\top \mathbf{v} + \mathbf{v}^\top \mathbf{X}^{-1} \mathbf{v}. \end{aligned}$$

## Distribuição Normal Multivariada

### Distribuição Marginal

Seja  $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , com  $\boldsymbol{\mu} \in \mathbb{R}^d$  e  $\boldsymbol{\Sigma} \in \mathbb{R}^{d \times d}$ . Suponha que  $\mathbf{X}$  pode ser particionado de forma que tenha-se

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_1 & \boldsymbol{\Sigma}_2 \\ \boldsymbol{\Sigma}_2^\top & \boldsymbol{\Sigma}_3 \end{bmatrix}$$

com  $\boldsymbol{\mu}_1 \in \mathbb{R}^k$ ,  $\boldsymbol{\mu}_2 \in \mathbb{R}^{d-k}$ ,  $\boldsymbol{\Sigma}_1 \in \mathbb{R}^{k \times k}$ ,  $\boldsymbol{\Sigma}_2 \in \mathbb{R}^{k \times (d-k)}$  e  $\boldsymbol{\Sigma}_3 \in \mathbb{R}^{(d-k) \times (d-k)}$ , para  $k < d$ . Então,  $\mathbf{X}_1 \sim \mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$  e  $\mathbf{X}_2 \sim \mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_3)$ .

### Distribuição Condicional

Considere  $\mathbf{X}$  como anteriormente. Então,

$$\begin{aligned} \mathbf{X}_1 \mid \mathbf{X}_2 &\sim \mathcal{N}(\hat{\boldsymbol{\mu}}_1, \hat{\boldsymbol{\Sigma}}_1) \text{ com } \begin{cases} \hat{\boldsymbol{\mu}}_1 = \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_3^{-1} (\mathbf{X}_2 - \boldsymbol{\mu}_2) \\ \hat{\boldsymbol{\Sigma}}_1 = \boldsymbol{\Sigma}_1 - \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_3^{-1} \boldsymbol{\Sigma}_2^\top \end{cases}, \\ \mathbf{X}_2 \mid \mathbf{X}_1 &\sim \mathcal{N}(\hat{\boldsymbol{\mu}}_2, \hat{\boldsymbol{\Sigma}}_2) \text{ com } \begin{cases} \hat{\boldsymbol{\mu}}_2 = \boldsymbol{\mu}_2 + \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_1^{-1} (\mathbf{X}_1 - \boldsymbol{\mu}_1) \\ \hat{\boldsymbol{\Sigma}}_2 = \boldsymbol{\Sigma}_2 - \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_1^{-1} \boldsymbol{\Sigma}_2^\top \end{cases}. \end{aligned}$$

### Combinação Linear

Tome  $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}_X, \boldsymbol{\Sigma}_X)$  e  $\mathbf{Y} \sim \mathcal{N}(\boldsymbol{\mu}_Y, \boldsymbol{\Sigma}_Y)$ . Então,

$$\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y} + \mathbf{c} \sim \mathcal{N} \left( \mathbf{A}\boldsymbol{\mu}_X + \mathbf{B}\boldsymbol{\mu}_Y + \mathbf{c}, \mathbf{A}\boldsymbol{\Sigma}_X \mathbf{A}^\top + \mathbf{B}\boldsymbol{\Sigma}_Y \mathbf{B}^\top \right).$$

## Referências

- Petersen, K. B. e M. S. Pedersen (out. de 2008). *The Matrix Cookbook*. Version 20081110. URL: <http://www2.imm.dtu.dk/pubdb/p.php?3274>.
- Soch, Joram et al. (jan. de 2024). *StatProofBook/StatProofBook.github.io: StatProofBook 2023*. Versão 2023. DOI: [10.5281/zenodo.10495684](https://doi.org/10.5281/zenodo.10495684). URL: <https://doi.org/10.5281/zenodo.10495684>.